影像表格文字化的實作與學習

作者：薛詠謙

目錄

壹、 動機 2
貳、 時間線(甘特圖) 2
參、 資料蒐集 3
一、 影像預處理 3
(一) 二值化 3
二、 文字辨識 3
(一) Tesseract 3
(二) PaddleOCR 4
(三) 小結 4
肆、 操作方法 4
一、 外圍邊線辨識與分割 4
(一) 消除文字 5
(二) 辨識邊線 5
(三) 分割表格區段 6
程式架構演進：為什麼需要區域切割？ 6
二、 表格內部邊線辨識 7
(一) 前製處理 7
撰寫歷史 7
(二) 偵測橫線 8
(三) 偵測直線 9
(四) 統一線寬 9
關於矩陣轉置策略： 9
關於為何採用`keep_last_line`： 9
(五) 相交點計算 10
布林運算的好用之處 10
三、 單元格分割 11
(一) 原始演算法 11
原始演算法簡介 11
(二) 最終演算法： 12
文字辨識： 12
四、 資料結構化 13
伍、 我的收穫與反思 14
未來展望 14
參考文獻 14

壹、 動機

在尋找合適校系的過程中，我發現 University TW 所提供的分數搜尋功能非常實用。 不過，該網站的資料更新速度並不一定與官方同步，而 **大學甄選入學委員會** 所公布的錄取分數資料又多以 **圖片表格** 的形式呈現，難以直接整理或分析。

因此，我產生了想要將影像表格轉換成可數位化利用文字資料的想法，因此，我開始學習 **OCR**（光學文字辨識）技術，並嘗試實現影像中文字資料的自動化擷取與轉換。

貳、 時間線(甘特圖)[1]

表 1　Oxx = Oct. xx, Nxx = Nov. xx

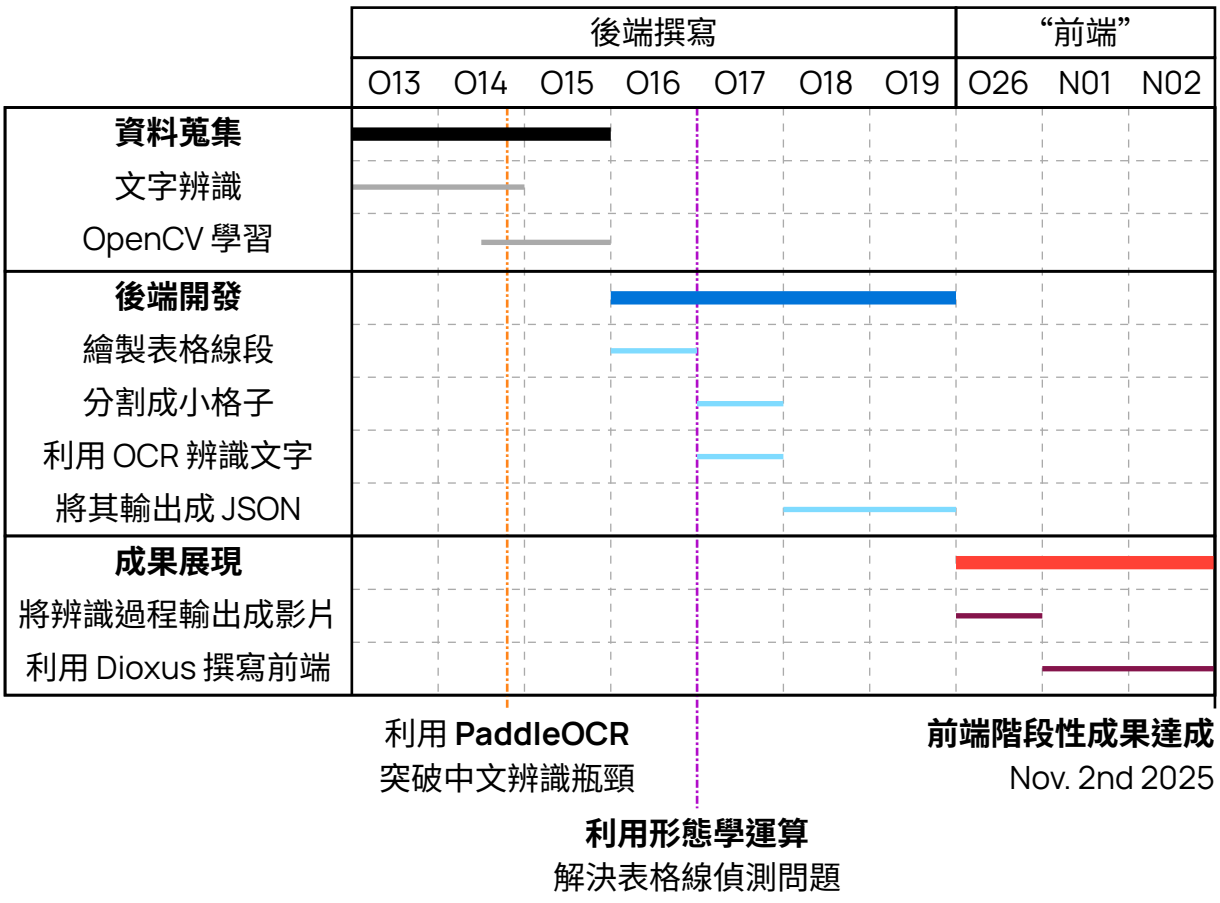

專案現況與規劃：

截至 11 月 2 日，我已完成:

- 後端辨識引擎 (100%)
- 表格切割與資料結構化 (100%)
- 辨識過程視覺化影片
- 前端介面開發中 (85%、剩下與大考中心結合的部分)

[1]平日每天約莫花兩小時、週末每天約莫花六小時在開發與資料蒐集上。

開發策略：

我採用了 Proof-of-Concept 優先的開發方式：先快速實作核心功能 驗證技術可行性，再回頭處理 technical debt 和程式品質優化。 這種迭代開發策略讓我能在最短時間內，專注於最關鍵的技術挑戰 ——表格辨識與切割的演算法實作。

叁、 資料蒐集

在有了這個想法之後，大約花了週末左右做資料蒐集，尋找是否有前人所做之成果。 在閱讀了 [1] 與 [2] 之後，我將影像表格分析流程簡略分為以下幾個步驟：

1. **影像前處理**：對原始影像進行去噪、二值化或對比度等調整。
2. **表格分割**：偵測並標註表格的行列結構，將整體表格拆分為單元格。
3. **文字辨識**：對每個單元格進行 OCR 辨識，取得對應文字內容。
4. **轉換輸出格式**：將最終文字結果整理成結構化資料，如 `csv` 或 `json` 。

一、 影像預處理

（一） 二值化

`threshold(thresh: f64)` 函式可將灰階影像轉換為純黑與純白的二值化影像。 然而，由於中文字筆劃粗細不一，閾值 (`thresh`) 的設定若不恰當，可能會降低文字辨識的準確度。

檢定標準	檢定標準	檢定標準
圖 1　閾值=100	圖 2　閾值=150	圖 3　閾值=200

因此，雖然在此範例中使用 圖 2（閾值 = 150）的二值化處理結果尚可接受， 但鑒於本專案涉及不同文字樣式，最終我決定在文字辨識的預處理階段不採用二值化。

二、 文字辨識

（一） Tesseract

將中文文字影像直接輸入 Tesseract 進行辨識時，即使經過灰階化等前處理，辨識效果仍不盡理想。推測原因可能在於大考中心提供的檔案 **解析度** 過低[3]，導致模型無法正確辨識文字。

`tesseract figure-1.png - -l chi_tra`
無法 辨識出文字

不過，Tesseract 在數字的辨識上表現十分精準，能穩定且無誤地擷取出校系代碼欄位的資料。

`tesseract figure-2.png - -c tessedit_char_whitelist=0123456789`
成功辨識出 011012

（二） PaddleOCR

PaddleOCR 是由百度開發的文字辨識工具，相較於 Tesseract ，在中文文字的擷取上具有顯著的提升。

在大多數情況下，PaddleOCR 能夠成功辨識中文文字，其特色包括：

- 對中英文混合及標點符號具有良好容錯性，大部分情況下都能正確辨識，例如在圖 6 成功辨識出「(英文+數學 A)25」。
- 少數情況下可能漏字，例如在 圖 4 中僅辨識出「（華語文教學組）」。
- 純數字辨識有時也會漏字，如在 圖 5 中僅辨識出「1012」。

中國文學系乙組(華語文教學組) 圖 4	011012 圖 5	(英文+數學A)25 圖 6

（三） 小結

綜上所述，將`tesseract`用於單元格的純數字辨識，而將 PaddleOCR 作為主要文字辨識工具，似乎為最佳組合。

肆、 操作方法

根據 圖 7 所示，來源影像包含多個表格區段，必須先將主要區塊切出，才有辦法進行更細緻的分割。 因此，需要先辨識各區域的 **外圍邊線** 並進行分割，再辨識表格內的 **分割線** ，將表格切分成單元格，最後進行 **文字辨識**，並將結果整理成結構化的 JSON 格式。

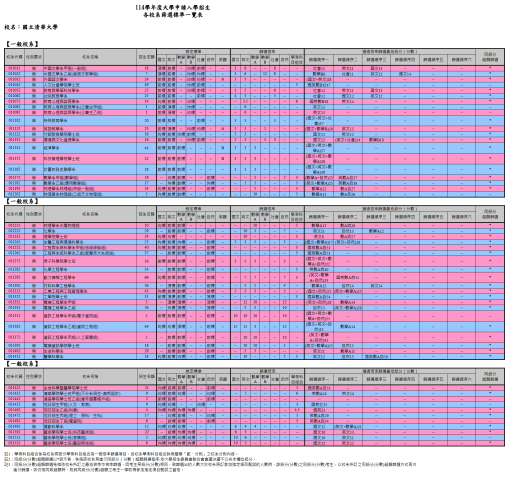

圖 7

處理流程可簡述如下：

外圍邊線辨識 → 區域分割 → 表格邊線辨識 → 單元格分割 → 文字辨識 → 將資料結構化

一、 外圍邊線辨識與分割

根據 [1]，可使用`find_contours_with_hierarchy`函數進行直線邊緣偵測。然而，此方法同時會偵測到文字筆劃中的直線，導致難以準確判定外框邊界。

（一） 消除文字

為消除文字干擾，可採用**膨脹與腐蝕（morphological closing）**處理。

```
let kernel =
    get_structuring_element(imgproc::MORPH_RECT, Size::new(20, 5),
Point::new(-1, -1))?;

let mut closed = Mat::default();

morphology_ex(
    &thresh,
    &mut closed,
    imgproc::MORPH_CLOSE,
    &kernel,
    Point::new(-1, -1),
    1,
    BORDER_CONSTANT,
    Scalar::default(),
)?;
```

程式 1　其中 `thresh` 為經過二值化的影像

由 程式 1 和轉換過後的 圖 8 可見，以長 20、寬 5 的矩形結構元素（kernel）進行運算，能有效的腐蝕掉文字，不過同時也腐蝕掉了表格。 為保留表格結構，可將處理後的影像與原始影像進行 `bitwise_or` 運算，以刪除文字，如 圖 9 所見。

圖 8　經過腐蝕過後的圖像

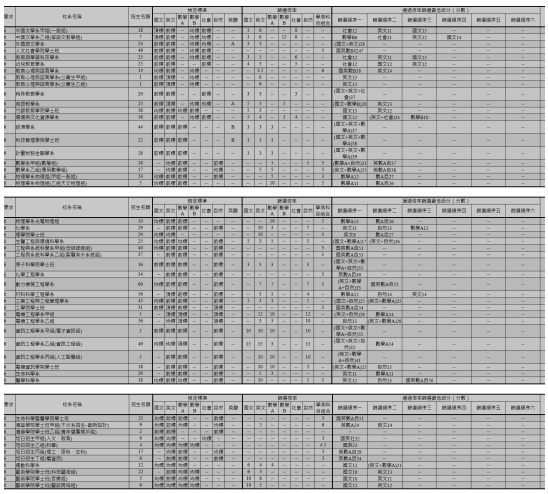

圖 9　經 bitwise_or 合併的圖像

（二） 辨識邊線

如程式 2 所示，將影像經由 `threshold` 函數進行二值化處理後，再執行 `bitwise_not` 運算，即可得到如 圖 10 之結果。

```rust
let mut thresh = Mat::default();
threshold(&output, &mut thresh, 254.0, 255.0,
THRESH_BINARY)?;
bitwise_not(&thresh.clone(), &mut thresh, &no_array())?;
```

程式 2　其中 `output` 為經過 `bitwise_or` 處理過後的影像

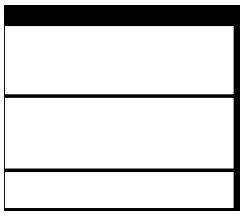

圖 10

（三） 分割表格區段

```rust
let mut contours = Vector::<Vector<Point>>::new();
let mut hierarchy = Vector::<Vec4i>::new();
find_contours_with_hierarchy(
    &thresh,
    &mut contours,
    &mut hierarchy,
    imgproc::RETR_EXTERNAL,
    imgproc::CHAIN_APPROX_SIMPLE,
    Point::new(0, 0),
)?;
let mut blocks: Vec<Rect> = contours
    .iter()
    .map(|contour| {
        let rect = imgproc::bounding_rect(&contour).unwrap();
        let area = (rect.width * rect.height) as f64;
        (rect, area)
    })
    .collect();

// sort by y-values first
blocks.sort_by(|a, b| a.y.cmp(&b.y).then_with(|| a.x.cmp(&b.x)));

let blocks_mat = blocks
    .into_iter()
    .map(|rect| Mat::roi(img, rect).map(|x| x.clone_pointee()))
    .collect::<Result<Vec<_>, opencv::Error>>()?;
```

程式 3　其中 `thresh` 為經過 `bitwise_not` 處理過後的影像

最後如 程式 3 所見，利用 `find_contours_with_hierarchy` 與 `Mat::roi` 即可將原影像分割成三個子區塊。

程式架構演進：為什麼需要區域切割？

專案初期，我是直接將完整影像送入 小節 二 處理。但發現了一個問題：來源影像包含多個表格區段，而區塊之間的 garbage data （標題、註解文字等）會干擾 小節 四 的邏輯判斷。

透過長久的 debug，發現問題不在邊線辨識，而是**缺少預處理步驟**。因此回頭開發區域切割功能。

二、 表格內部邊線辨識

在多種表格偵測方法中，[1] 與 [2] 採用 Canny 邊緣偵測 搭配 HoughLinesP 進行線段擷取；而我後來在論壇討論中看到一種以 形態學運算 為核心的做法，實際測試後發現參數量更少，前處理流程也更簡潔。

由於本專案處理的影像來源並非真實掃描，而是沒有噪點的純數位圖片，因此這類基於形態學的流程在本應用情境中 更適合，也能更穩定地取得表格線條。

（一） 前製處理

```
let mut gray_inv = Mat::default();
bitwise_not(&gray, &mut gray_inv, &no_array())?;
let mut binary = Mat::default();
threshold(&gray_inv, &mut binary, 90.0, 255.0, THRESH_BINARY)?;
```

程式 4　`gray` 為將圖像灰白化後的圖片

因為我們要偵測的是邊線，所以將圖像負片化能使邊線轉換成白色，較易偵測。

```
let dilate_kernel = get_structuring_element(MORPH_RECT, Size::new(3, 1),
Point::new(-1, -1))?;
let mut binary_dilated = Mat::default();
dilate(
    &binary,
    &mut binary_dilated,
    &dilate_kernel,
    Point::new(-1, -1),
    1,
    BORDER_CONSTANT,
    morphology_default_border_value()?,
)?;
```

程式 5

再先進行簡單的膨脹運算，將文字變得更粗，如 程式 5 可見。

撰寫歷史

原本的流程直接進入橫線偵測，沒有 `dilate` 這個步驟，但由於辨識時發現有部分區域偵測出的邊緣有小瑕疵，導致後來切割單元格的時會裁到邊線，影響文字辨識。

經過繁複 debug 過後，在二值化後增加簡單的膨脹運算，能讓邊線更 完整，提高辨識穩定性。

（二） 偵測橫線

```
let horizontal_kernel =
  get_structuring_element(MORPH_RECT, Size::new(kernel_width, 1),
Point::new(-1, -1))?;

let mut detected = Mat::default();

morphology_ex(
    &binary,
    &mut detected,
    MORPH_OPEN,
    &horizontal_kernel,
    Point::new(-1, -1),
    1,
    BORDER_CONSTANT,
    morphology_default_border_value()?,
)?;
```

程式 6　`binary` 圖片是經過 程式 4 和 程式 5 處理過後的圖像

透過使用極扁的 `kernel` 並施行開運算（MORPH_OPEN），可將非橫向排列的區域轉換為背景。 因此，調整 程式 6 中的 `kernel_width` 會影響處理結果。

經測試，圖 11 與 圖 12 仍可觀察到未完全腐蝕的文字， 最終決定將 `kernel_width` 設為 60，以確保文字完全被去除。

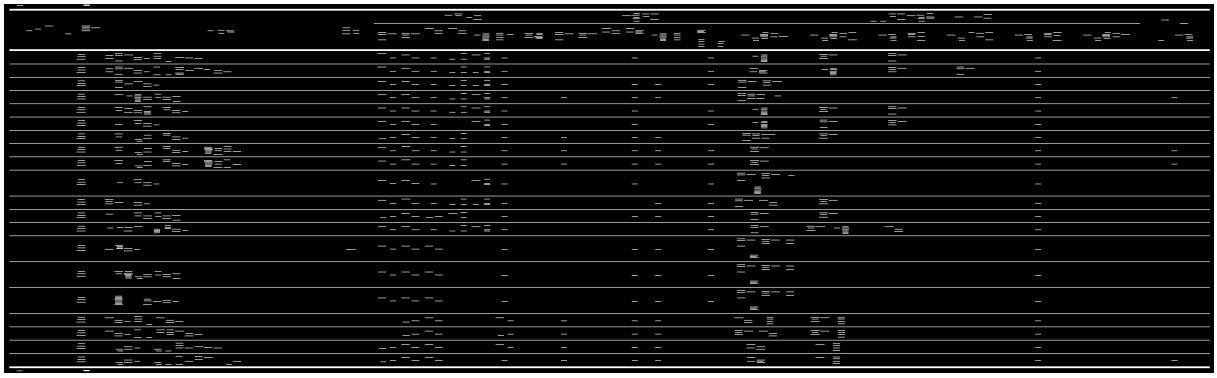

圖 11　`kernel_width` = 10

圖 12　`kernel_width` = 20

圖 13　`kernel_width` = 40

（三） 偵測直線

同樣的邏輯可以套用在直線上，而`kernel_height`這次設定為 40，因為有較多更短的直線。

```
let vertical_kernel =
  get_structuring_element(MORPH_RECT, Size::new(1, kernel_height),
Point::new(-1, -1))?;
```

程式 7

（四） 統一線寬

由於`.data_bytes_mut()`必須取得一塊連續記憶體，因此原本在 OpenCV 中不是連續記憶體的列(column)，無法直接使用該方法進行操作。

為了統一處理線寬，可利用矩陣轉置，將原本的列(column)轉換為行(row)，使其變成連續的記憶體區塊，即可直接傳入`keep_middle_line`。

關於矩陣轉置策略：

最初我使用`.at(x,y)`逐元素將列(column)轉換成`Vec`進行處理。這個方法可以運作，但有兩個問題：

1. 只能線性執行，無法平行化
2. 程式碼不直觀

而在重構時想到：既然列不是連續的，那把整個矩陣轉置不就行了，把原本的列變成行（連續記憶體），就能可直接操作。

關於為何採用`keep_last_line`：

目前採用保留最後一行的方案，但這並非一定是最佳解答。在部分測試案例中，保留第一行或中間那行的效果更好。由於本專案重點在於驗證整體技術可行性，沒有時間深究原因，因此最後採用較穩定的「保留最後一行」策略。

```rust
// transpose to make columns continous
transpose(&h_lines.clone(), &mut h_lines)?;
for y in 0..h_lines.rows() {
    keep_last_line(h_lines.row_mut(y)?.data_bytes_mut()?);
}
transpose(&h_lines.clone(), &mut h_lines)?;

for y in 0..v_lines.rows() {
    keep_last_line(v_lines.row_mut(y)?.data_bytes_mut()?);
}

fn keep_last_line(line: &mut [u8]) {
    let line_with_index =
line.iter().copied().enumerate().collect::<Vec<_>>();

    // if consectuive elements are the all 255, group them together
    let consecutive_runs = line_with_index
        .chunk_by(|(_, lhs), (_, rhs)| *lhs == 255 && *rhs == 255)
        // prevents boundary condition of [255, 0]
        .filter(|x| !x.iter().rev().any(|x| x.1 == 0));
    line.fill(0);
    for stride in consecutive_runs {
        line[stride[stride.len() - 1].0] = 255;
    }
}
```

程式 8

（五） 相交點計算

如 程式 9 中可見，可利用 `bitwise_and` 計算線條的交點。然而，交點結果儲存在 `Mat` 影像中，不易直接運用。因此，使用 `find_non_zero` 將非零像素（即交點）轉換為 `Vec<Point>`，以便後續處理。

布林運算的好用之處

最初用雙層 for 迴圈逐步檢查像素交點，這種 imperative 的寫法雖然簡單但巢狀層級過深，回頭閱讀時會增加認知複雜度。重構時想到：既然有 `bitwise_and`，何不直接計算交點？然後再利用 OpenCV 所提供的 `iter()` 函數，即可在無 nesting 的方式，撰寫出效果相同，但更直觀、更好理解的程式碼。

這次重構利用了 「Never Nester」 原則[2]：透過提前返回、 Declarative Coding 等概念和 API 的善用，將多層巢狀迴圈轉換為清晰的 pipeline，降低閱讀程式碼時的認知負荷。

[2] Why You Shouldn't Nest Your Code by CodeAesthetic

```rust
let mut intersection_mat = Mat::default();
bitwise_and(&v_lines, &h_lines, &mut intersection_mat, &no_array())?;

let mut points_mat = Mat::default();
find_non_zero(intersections_mat, &mut points_mat)?;

let mut intersections = points_mat
    .iter::<Point>()
    .into_iter()
    .flatten()
    .map(|e| (e.1.x, e.1.y))
    .collect::<Vec<_>>();
```

程式 9

三、 單元格分割

大部分文獻所提供的分割方法都是存在表格為「整齊」的前提下撰寫的，而如此的切割方法(程式 10)假如遇到如 圖 14 或 圖 15 的情況就會無法將完整的單元格切割出來。

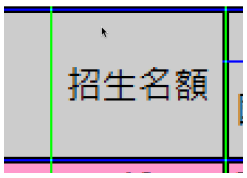

圖 14

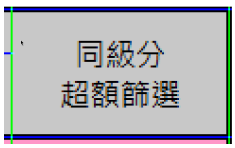

圖 15

(一) 原始演算法

程式 10 對左邊有三個交點的單元格(圖 15)有效，但對右邊有三個交點的單元格(圖 14)卻會失效。

```rust
intersections.sort_unstable();

// 使得每個窗口都必須是同一列(column)
let iter = intersections.windows(2).filter(|w| w[0].0 == w[1].0);

for window in iter {
    let [top_left, bottom_left] = window else {
        unreachable!()
    };

    let bottom_right = (bottom_left.0 + 1..max_x)
        .find(|e| table.contains(&(*e, bottom_left.1)))
        .map(|x| (x, bottom_left.1));


    let cell = Mat::roi(gray, Rect::from_points(top_left, bottom_right))?;

}
```

原始演算法簡介

採用逐列掃描（滑動窗口，每次取 2 個元素）：取左上和左下兩點，從左下向右搜尋右下角。

程式 10 `table` 為將 `interesctions` 轉換成 `HashSet` 之後的變數

解決這個問題最「標準」的方法是判別目前的格子到底是在 圖 15 還是 圖 14 的情況，但最後我有想到一個能避免複雜判斷的方式。

（二） 最終演算法：

1. 利用滑動窗口(程式 10)得知左上、左下兩點
2. 向右搜尋右上、右下兩點（程式 11）
3. 形成兩個候選矩形並比較面積（程式 12）
4. 取較大者作為單元格邊界

```
let top_right = (top_left.0 + 1..max_x)
    .find(|e| table.contains(&(*e, top_left.1)))
    .map(|x| (x, top_left.1));

let bottom_right = (bottom_left.0 + 1..max_x)
    .find(|e| table.contains(&(*e, bottom_left.1)))
    .map(|x| (x, bottom_left.1));
```

程式 11

```
fn get_biggest_possible_bounding_box(
    [top_left, top_right, bottom_left, bottom_right]: [Point_<i32>; 4],
) -> Rect_<i32> {
    let rect1 = Rect::from_points(
        (bottom_left.x, bottom_left.y).into(),
        (top_right.x, top_right.y).into(),
    );

    let rect2 = Rect::from_points(
        (top_left.x, top_left.y).into(),
        (bottom_right.x, bottom_right.y).into(),
    );

    if rect1 > rect2 {
        rect1
    } else {
        rect2
    }
}
```

程式 12

在視覺化影片中，可以看到在招生名額(0:09)、檢定標準(0:12)等單元格都正確判斷。

文字辨識：

在經`Mat::roi`獲得單元格，輸出成圖片檔給 PaddleOCR 做辨識後即可獲取到中文文字，至於何時會使用到 Tesseract 則會在 小節 四 時詳細描述。

四、 資料結構化

程式碼簡化邏輯如下：

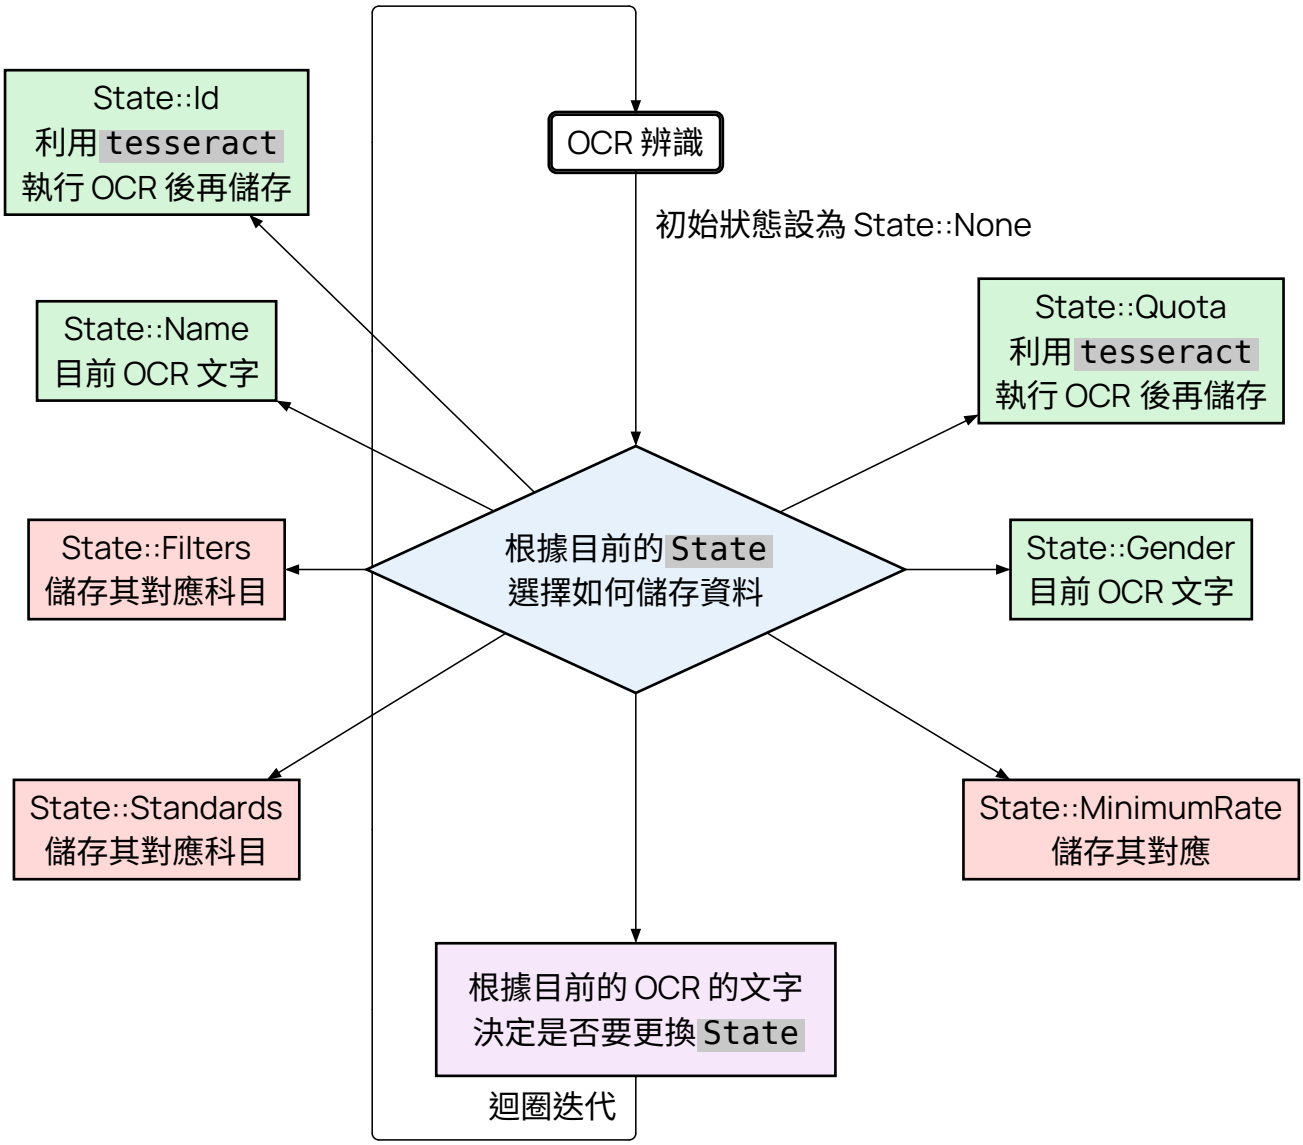

`State::Filters`、`State::Standards`、`State::MinimumRate`皆有子狀態，簡易定義於 程式 13 可見。

```
pub enum State {
    Id,
    Gender,
    Name,
    Quota,
    Standards(Majors),
    Filters(Majors),
    MinimumRate(Level),
    None,
}
```

實際程式碼

由於實際程式碼過於龐長，不適合於本報告中呈現，完整程式碼可於 GitHub 中查看。

程式 13　其中`Majors`是國文、英文等科目的枚舉，`Level`代表第幾篩選

伍、 我的收穫與反思

這次專案讓我深刻體會到圖像辨識比想像中困難許多。最大的挑戰在於：如何用「程式邏輯」有理有據地將圖像一步步轉換成目標形式。影像不像文字資料有明確的結構，每個像素只是一個數字。要從這些數字中「看出」表格、文字、邊線，需要反覆嘗試不同演算法、調整各種參數，才能得到令人滿意的結果。

在各類圖像演算法中，我對**形態學運算**的多功能性感到非常敬佩。光是 `MORPH_OPEN` 和 `MORPH_CLOSE` 兩者的組合，就能創造出無限可能，這次在消除文字和統一線條粗細就有使用到。雖然這次專案沒機會用到其他模式（如 `TOPHAT`、`BLACKHAT` 等），但這次對形態學運算的學習經驗，相信能在未來幫助我設計出更多有趣的演算法。

撰寫程式時，我發現自己對 `bitwise_[or,and,not]` 的喜愛難以言喻。身為非常喜愛 Ranges 演算法（容器導向程式設計）的人[3]，我深知：**對整個「容器」操作，比對個別「元素」操作要簡單許多**。而在影像處理中，這個概念更加明顯。只要做好前置處理，大部分 步驟根本不需要遍歷整個矩陣，只要用布林運算就能得到答案。又由於他的可擴展性，編譯器可以更好的「看到」各種優化，如 SIMD 加速等。

未來展望

這個專案讓我對電腦視覺和影像處理產生興趣。未來不管是利用學習更多形態學運算的應用，還是圖像演算法的開發都是可以精進自己的方向。

更重要的是，這次經驗讓我確定：我喜歡用程式解決真實問題。在高三學測的壓力下，這個專案成了我唯一的避風港。當我 debug 到凌晨，當我看到表格終於被正確切割，當我發現用 `bitwise_and` 就能優雅解決問題時——那種成就感，讓我忘記了考試的焦慮。

從發現問題（University TW 資料更新慢）到實作解決方案， 整個過程充滿挑戰但也很有成就感。這正是我想在資工系深入學習的—— 用技術創造價值，解決實際問題。不是為了考試而學，而是因為真心喜歡，這才是我選擇資工系的原因。

參考文獻

[1] 蔡桓銘, 「用 Tesseract 結合 LSTM 模型實作手填表格辨識」, 2021. doi: 10.6846/TKU.2021.00596 .

[2] Johnny Chang, 「使用 python 萃取掃描文件中的表格(一)切豆腐篇」. [線上]. 載於: https://between2058.medium.com/使用 python 萃取掃描文件中的表格-一-切豆腐篇-d5b65b7ec320

[3] Willus Dotkom, 「Optimal image resolution (dpi/ppi) for Tesseract 4.0.0 and eng.traineddata?」. [線上]. 載於: https://groups.google.com/g/tesseract-ocr/c/Wdh_JJwnw94/m/24JHDYQbBQAJ?pli=1

[3]此為我擔任資研社副社長時撰寫的教材，介紹如何使用 C++20 的 Ranges 和 Views 進行容器導向程式設計。