

影像表格文字化的實作與學習

作者：薛詠謙

1、動機

在尋找合適校系的過程中，我發現 University TW 所提供的分數搜尋功能非常實用。不過，該網站的資料更新速度並不一定與官方同步，而 大學甄選入學委員會 所公布的入取分數資料又多以 圖片表格 的形式呈現，難以直接整理或分析。

因此，我產生了想要將影像表格轉換成可數位化利用文字資料的想法，因此，我開始學習 OCR（光學文字辨識）技術，並嘗試實現影像中文字資料的自動化擷取與轉換。

2、資料蒐集

根據 [1]，影像表格分析流程可分為以下幾個步驟：


1. **影像前處理**：對原始影像進行去噪、二值化或對比度等調整。
2. **表格分割**：偵測並標註表格的行列結構，將整體表格拆分為單元格。
3. **文字辨識**：對每個單元格進行 OCR 辨識，取得對應文字內容。
4. **轉換輸出格式**：將最終文字結果整理成結構化資料或表格文字格式。

2.1 純文字辨識

2.1.1 **tesseract**

將中文文字影像直接輸入至 **tesseract** 進行辨識時，即便經過去除表格邊框等前處理步驟，仍未能有效提升辨識效果。

不過，**tesseract** 在 **數字** 的辨識上表現十分精準，能穩定且無誤地擷取出 **校系代碼** 欄位的資料。



```
tesseract figure-2.png -c  
tesseract_char_whitelist=0123456789  
成功辨識出 011012
```

2.1.2 **PaddleOCR**

PaddleOCR 是百度開發的文字辨識工具，相較於 **tesseract**，在中文文字的擷取上具有顯著的提升。

Bibliography

- [1] 蔡桓銘，“用 Tesseract 結合 LSTM 模型實作手填表格辨識，” Jan. 15, 2021. doi: [10.6846/TKU.2021.00596](https://doi.org/10.6846/TKU.2021.00596).